

MACHINE LEARNING CANVAS

PREDICTION TASK



Entrada: empresa/canal, janela (ex.: últimos 30 dias), posts históricos (texto + métricas), voz/banlist (opcional).

Subtarefas:

Retrieval k-NN (pgvector/cosine) dos textos para achar vizinhos dos *winners* e dos *fracos*.

Ranking por similaridade + **ER** = (likes+comentários+shares)/views.

Horários: agregação por hora/dia, ranqueando **Top-3** por ER mediano.

Geração estruturada (LLM) do **Guia 1 página** em **JSON** com: resumo, top insights, melhores horários, diretrizes de tom, “o que evitar”, 3–5 sugestões de posts com justificativa baseada nos dados.

Saída: JSON do **Guia de Postagem** (pronto para UI e PDF).

Tipo: **RAG** (retrieval + geração). Sem modelo supervisionado inicial.

DECISIONS



Gerar **Guia de Postagem 1 página** (JSON) com: melhores horários, 3–5 ideias de posts, melhorias de título/legenda e “o que evitar”.

Priorizar **temas/formatos** com maior probabilidade de engajamento, com base em similaridade aos “winners”.

Alertar **gaps** (ex.: pouca variedade de formatos, horário ruim).

VALUE



PROPOSITION

Economiza tempo e tira a fricção de idear.

Aumenta ER ao replicar padrões vencedores do próprio canal.

Entrega simples e acionável (JSON/PDF 1 página).

DATA COLLECTION



Upload de **CSV** (validação de schema; normalização de datas/timezone; IDs de canal).

Rotina de reproprocessamento após cada importação (gera embeddings + atualiza índices).

Log de importações e cobertura (quantos posts com embedding).

DATA SOURCES



Internos: empresa, canal, importacao, post (texto + métricas).

Externos (futuro): APIs YouTube/Instagram; tendências públicas por país.

IMPACT

SIMULATION

✓

Custo do erro: postar em horário ruim / repetir padrão fraco → queda de ER.

Teste offline: simular “se seguissemos as recomendações, qual seria o ER esperado?” (backtest por janelas).

Critérios: manter sugestões curtas, brand-safe, aderentes à voz da marca.

MAKING

PREDICTIONS

⇌

Quando: on-demand (ao abrir “Minha Empresa” ou clicar “Gerar Guia”) e pós-importação.

Frequência: a qualquer momento; recomendado 1× por dia por canal.

Latência alvo: 3–5 s por guia (cache de resultados recentes).

Recursos: 1 consulta DB + 1 busca k-NN + 1 chamada LLM.

BUILDING

MODELS

⚙️

Modelos em produção:

Índice vetorial (pgvector, IVFFlat/HNSW) para retrieval.

Pipeline de **prompt** (system + contexto dinâmico) para LLM.

Atualização: após novas importações (reindex + ANALYZE).

Janela de features/análises: últimos 30 dias (configurável).

FEATURES

▮▮▮

Embeddings de texto (dim 1536).

Tempo: hora do dia, dia da semana.

Linguagem: tamanho da legenda, nº de hashtags/emoji, presença de CTA.

Métricas normalizadas: ER; bins de views para evitar viés.

MONITORING

📶

Produto: # de guias gerados, taxa de uso, taxa de edição/aceitação das sugestões.

Negócio: uplift de ER vs. período anterior/controle; % posts nos **Top-3 horários**.

Saúde: latência e custo por guia, taxa de erro LLM, cobertura de embeddings, drift (mudança de distribuição de ER/temas).

Revisão: semanal (dash), mensal (retro e ajustes de prompt/features).